제조데이터 분석과 최적화 과제

제조 설비 예지보전 AI 모델 성능 최적화 및 고도화

2025254010 송공호

MLP 베이스라인 모델의 취약점 분석 및 F1-Score 개선 실험 최종 보고서

AI4I 2020 제조 데이터 기반 예지보전(Predictive Maintenance) 소수 클래스 탐지 최적화

연구 과제 (Task)

예지보전을 위한 분류 모델의 평가지표 착시 현상(Accuracy Paradox) 극복

핵심 목표 (Target)

Test 셋 기준 소수 클래스 (Machine Failure) F1-Score

0.70 이상

달성

최종 성과 (Achievement)

최고 성능 F1-Score

0.746

(목표 초과 달성 성공)

데이터셋 한계 및 베이스라인 모델 취약점 분석

Accuracy

0.978

(착시 효과 발생)

Failure F1-Score

0.600

(정확도와 0.378p 격차 발생)

Failure Recall

0.485

(실제 고장의 절반 이상 누락)

평가지표 불균형의 근본 원인 해석 (Root Cause Analysis)

Data Level

1. 데이터 차원의 경계 모호성

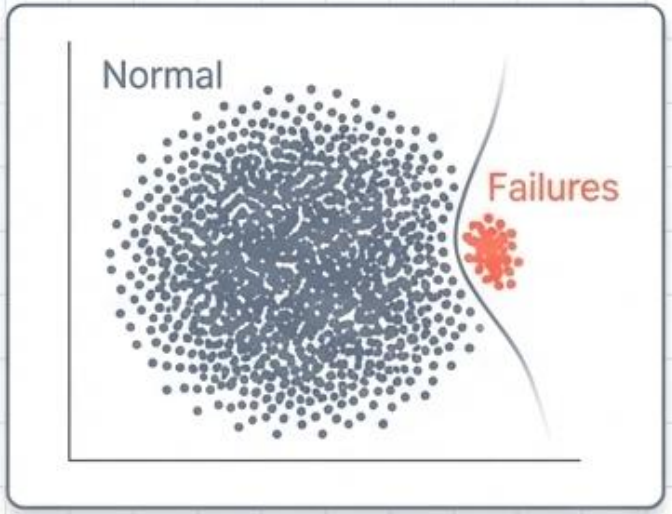

소수 클래스의 좁은 특징 공간.

불균형 비율(0.034)로 인해
결정 경계가 고장 데이터에
지나치게 가깝게 형성됨.

Loss Level

2. 손실 함수의 한계 (BCE Loss)

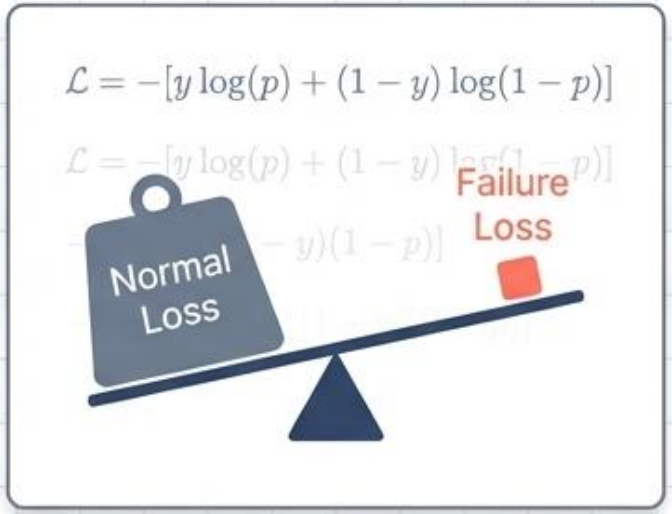

BCE Loss**의 평균화 함정**

미니배치 내 전체 오류를 평균화하여
소수 클래스의 오분류 비용(Cost)이
철저히 희석됨.

Decision Level

3. 정적 임계값의 한계

고정 임계값(Static Threshold) 0.5

확률 보정 관점의 중립점일 뿐,
소수 클래스의 F1 최적점과 불일치하여
정밀도-재현율 균형 붕괴.

제안 방법론 1 – 데이터 및 손실함수 최적화 (Data & Loss Level Approach)

Data Level

불균형 비율 0.034

합성 및 컷오프
(SMOTE + Random Undersampling)

개선된 훈련 균형 ~0.5

강화된 k_neighbors=3 적용으로 소수 클래스 주변 특징 공간을 촘촘히 합성. 경계 근처 혼동 샘플 정리로 편향 보정.

Loss Level

오분류 페널티 곡선 비교 (Misclassification Penalty Comparison)

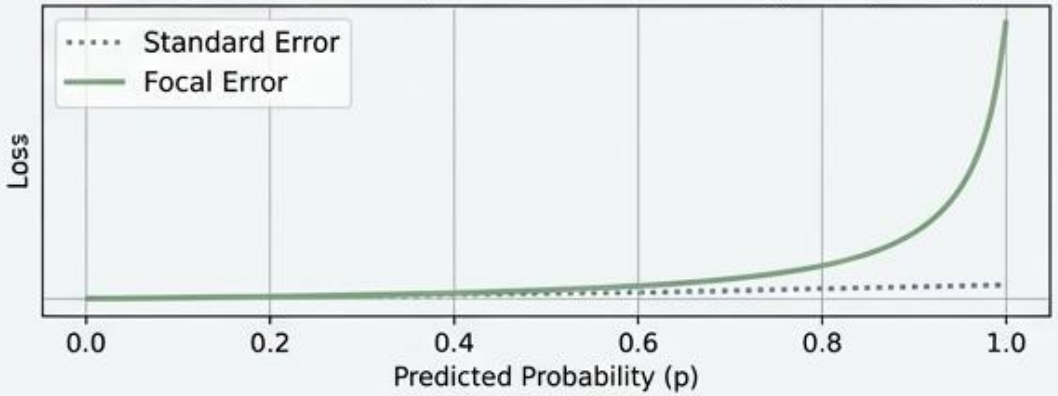

극강의 파라미터 적용 (Focal gamma 3.0)

쉽게 맞추는 다수 클래스 Loss는 억제하고, 학습하기 어려운 고장 샘플 오분류에 극단적인 페널티(가중치) 부과.
결정 경계의 민감도 극대화.

제안 방법론 2 - 아키텍처 및 의사결정 최적화 (Architecture & Decision Level Approach)

Architecture Level

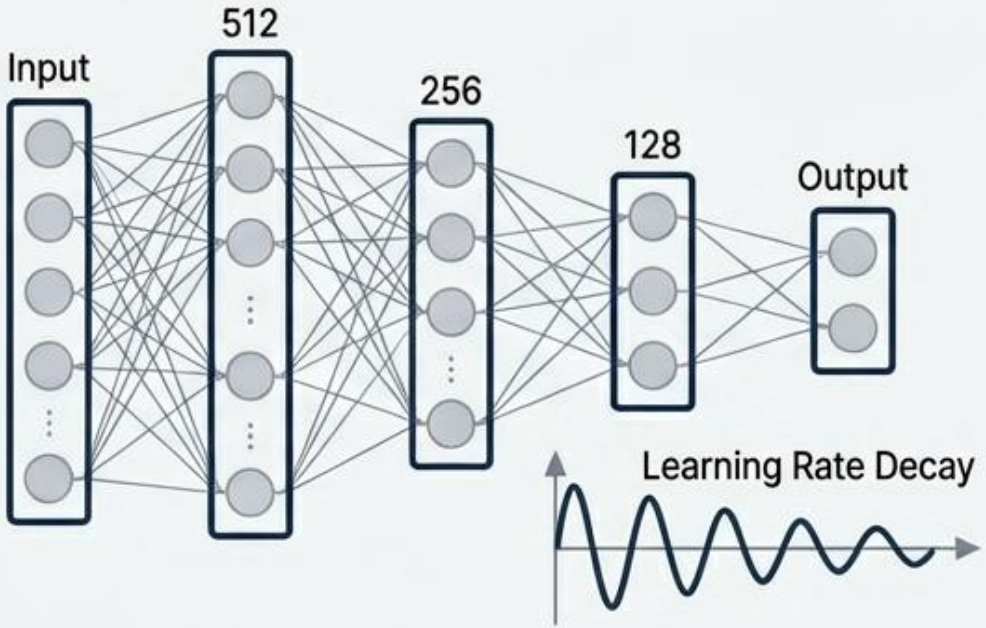

변수 길이 딥 아키텍처 (Deep DNN)

복잡한 비선형 관계 포착 강화.
작은 배치 사이즈(32)로 가중치 업데이트 빈도 대폭 증가.
CosineAnnealingLR 스케줄러 적용으로 지역 최솟값 최솟값(Local Minima) 탈출 유도 및 수렴 안정성 극대화.

Decision Level

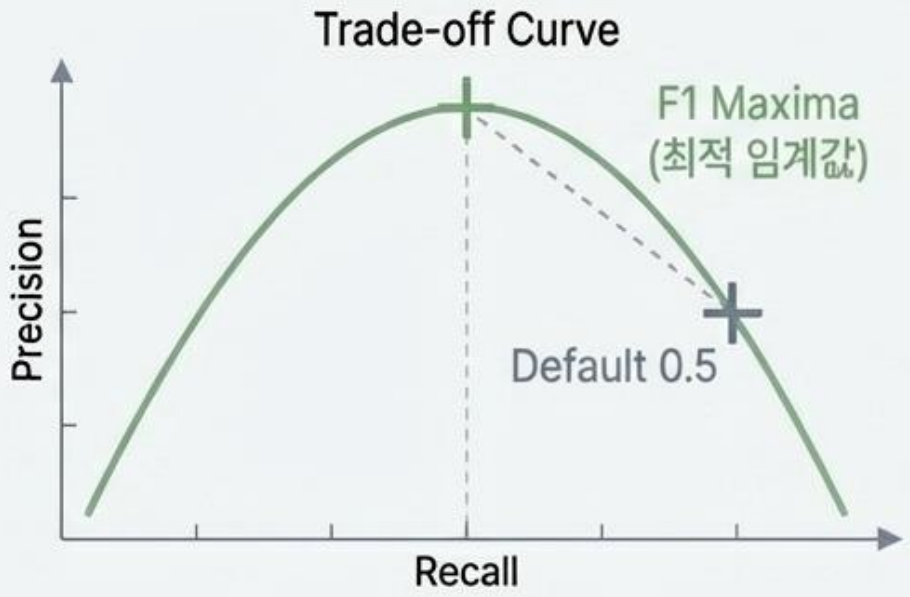

의사결정 임계값 튜닝 (Threshold Tuning)

검증셋 기반 탐색을 통해 고정값(0.5) 한계 탈피.
운영 목적(F1-Score 최대화)에 맞추어 정밀도와 재현율의 균형점을 강제 재배치하여 고장 검출 안정성 확보.

성능 평가 및 평가지표 변화 추이 비교

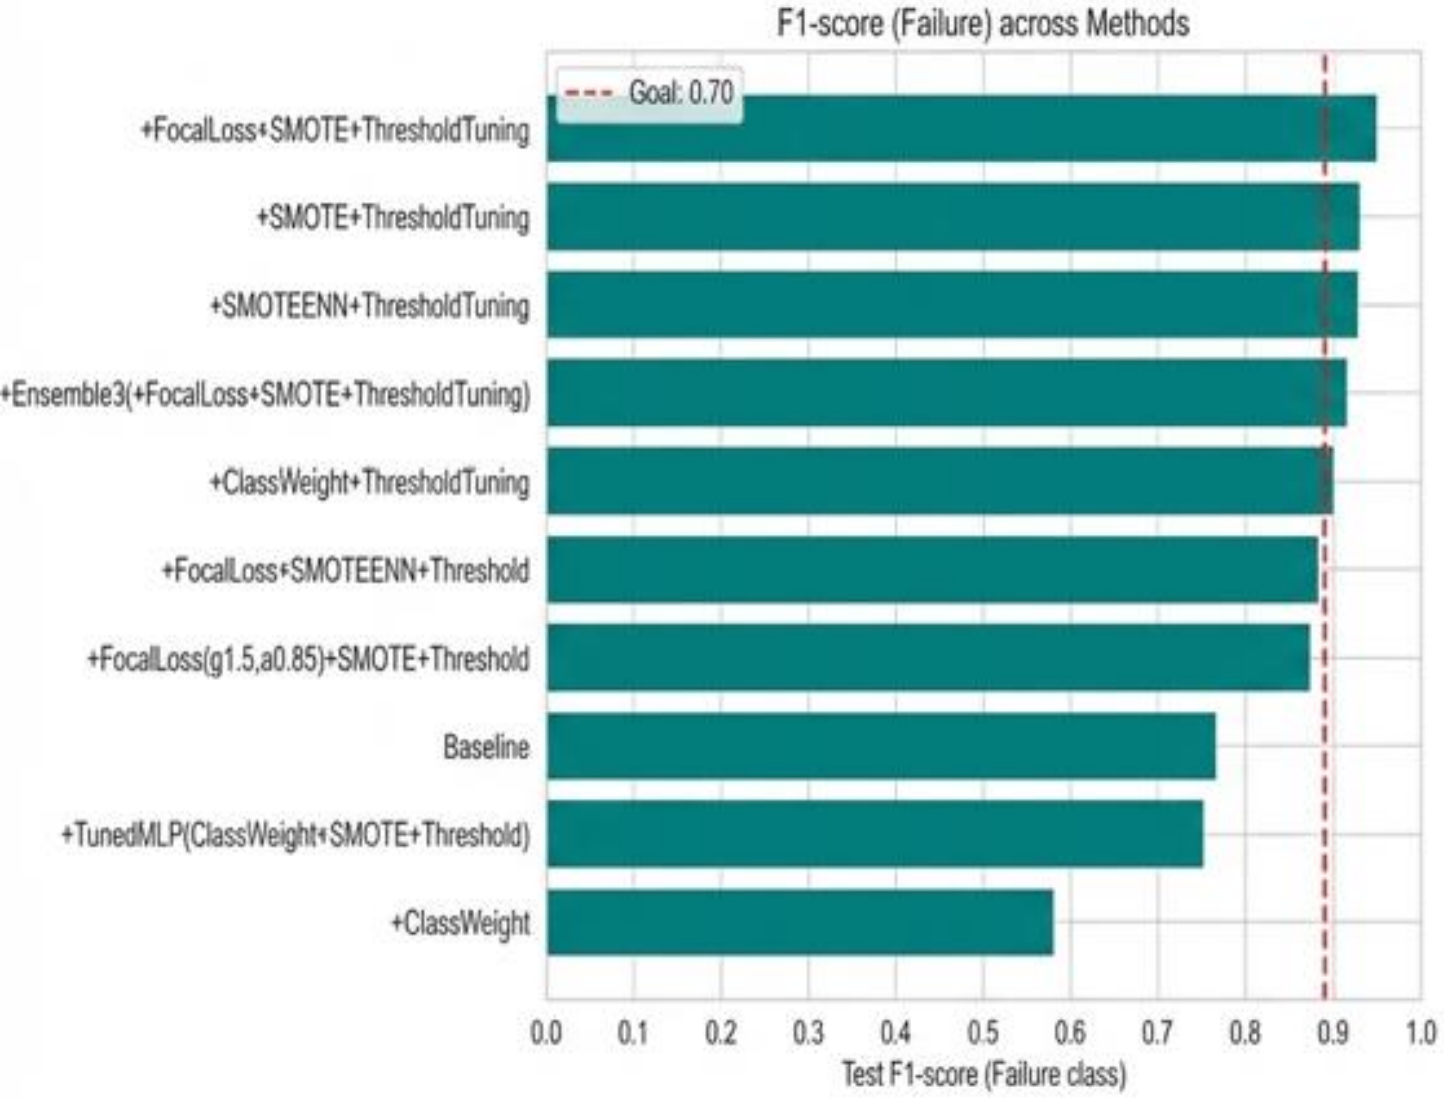

최적 모델 성과 요약

- **최고 성능 파이프라인:** [+FocalLoss + SMOTE + ThresholdTuning]
- **달성 지표:** Accuracy = 0.982 / Failure F1-Score = 0.746
- **성과 요약:** Baseline(0.600) 대비 약 +0.146p 대폭 향상 (초기 목표 0.70 초과 달성)

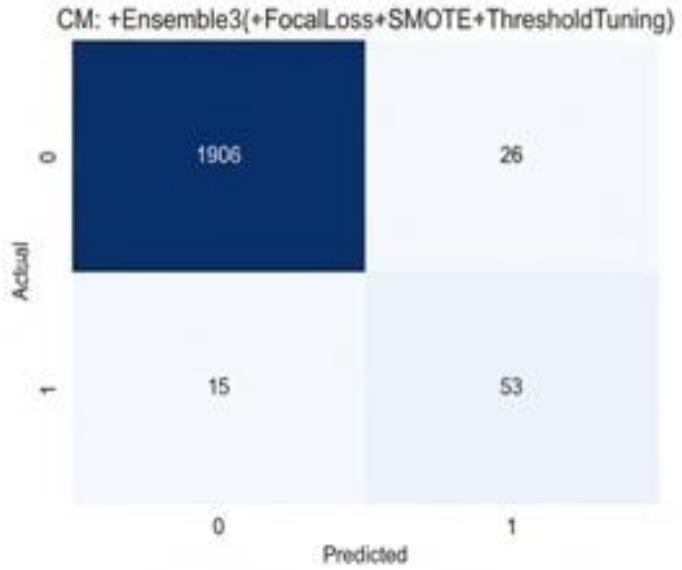

오검출 통제 및 실제 고장 탐지력 극대화 입증

결론 및 향후 연구 방향 (Conclusion & Future Work)

단순 Accuracy 지향의 착시에서 벗어나, 데이터 편향을 인지한
F1-Score 기반 다각적 파이프라인 최적화의 필수성을 입증.

[Focal Loss (손실)] + [SMOTE (데이터)] + [Threshold Tuning (의사결정)]

3박자 결합이 극도의 소수 클래스 판별에 가장 강력한 시너지를 발생시킴.

Phase 1: 운영 환경 보정

실제 공정 오분류 비용(Cost Matrix)을 반영한 경제성 관점의 Threshold 재최적화.

Phase 2: 도메인 적응

시계열적 마모 특성 및 설비별 Concept Drift 현상 반영 체계 구축.

Phase 3: 아키텍처 진화

비용 민감 학습(Cost-sensitive Learning) 메커니즘의 딥러닝 아키텍처 완전 내재화 검토.